

PronounSE の iOS 実機評価：インタラクティブな効果音生成の成立条件

1. 研究の目的

本研究の目的は、声真似から効果音を生成する PronounSE を iPhone 単体で動作させ、スマホ上で「その場でインタラクティブに効果音を作る」体験が成立するかを検証することである。

PronounSE は、ユーザーの声真似を入力として効果音を生成するシステムである。しかし、従来の実行環境は PC やサーバーを前提としており、スマートフォン単体で同じように動作するかは明らかではない。特に、iOS 上で Core ML を用いてモデルを実行する場合、モデル精度や計算ユニットの選択によって、速度・安定性・音質が大きく変わる可能性がある。

そこで本研究では、PronounSE を Core ML に変換し、iPhone 実機上で複数のモデル精度と計算ユニットを比較した。評価の目的は、単にモデルが動くかどうかではなく、ユーザーがその場で試しながら効果音を生成できる条件を明らかにすることである。

2. 評価の考え方

本研究では、「インタラクティブな効果音生成が成立する」条件を、次の 3 軸で定義する。

軸	内容	指標
① 速い	ユーザーがその場で待てるか	モデルロード時間 / 推論時間
② 壊れない	実行時に破綻しないか	clipping / crash / E5RT / 初回非決定性
③ 使える音	baseline に近い音が出るか	MCD / 聴感確認

ここで重要なのは、速度だけではインタラクティブ性は判断できない点である。たとえ推論が速くても、音が壊れたり、アプリがクラッシュしたり、生成音が baseline から大きく外れたりする場合、その条件は実用的とは言えない。したがって、本研究では 3 軸を同時に満たす条件を「成立候補」とする。

3. 実験条件

評価対象は、モデル精度 3 種類と計算ユニット 4 種類を組み合わせた 12 条件である。

精度	計算ユニット
Float32	cpuOnly / cpuAndGPU / cpuAndNE / all
Float16	cpuOnly / cpuAndGPU / cpuAndNE / all
Int8	cpuOnly / cpuAndGPU / cpuAndNE / all

入力には同一の `input_sample.wav` を使用し、iPhone 実機上で各条件のロード時間、安定性、出力音声を計測した。出力音声については、PyTorch 版 PronounSE の出力を baseline として、Core ML 版の出力との差を MCD により評価した。

4. ① 速い軸：モデルロード時間

モデルロード時間では、セルを選択してから音を出す準備ができるまでの時間を測定した。PronounSE では、Encoder、Decoder、HiFi-GAN の 3 モデルをロードする必要があるため、これらの合計時間を評価した。

結果として、CPU/GPU 系の条件では初回ロードが約 1 秒前後に収まり、キャッシュ後は約 0.1 秒程度まで短縮された。一方、Float16 および Int8 で Neural Engine を含む条件では、HiFi-GAN の初回ロードに 32～67 秒程度かかり、一部ではクラッシュも発生した。

条件	初回ロード	キャッシュ後	判定
CPU/GPU 系	約 0.7~1.2 秒	約 0.08~0.12 秒	成立候補
Float16 / Int8 × cpuAndNE / all	約 32~67 秒、またはクラッシュ	約 0.19 秒	不成立

この結果から、体感差を生む主要因はキャッシュ後のロードではなく、初回の特異化・コンパイル処理であることが分かった。特に、Float16 および Int8 の HiFi-GAN を ANE 向けに特異化する処理が大きなボトルネックとなっていた。




Figure 1: 初回モデルロード時間 (12 セル)

なお、各セルを 2 回目以降ロードする（行き来する）場合は、下図のとおり全セルが約 0.1~0.2 秒に収束する。体感差を生むのは各セルを初めて触った瞬間の初回特異化のみである。

5. ② 壊れない軸：安定性

安定性評価では、各条件で出力波形が clipping しないか、アプリがクラッシュしないか、初回実行時に非決定的な破綻が起きないかを確認した。

結果として、Float16 および Int8 で Neural Engine を含む条件では、決定論的な clipping が観測された。具体的には、F16 × cpuAndNE、F16 × all、Int8 × cpuAndNE、Int8 × all の 4 条件で、出力波形の RMS および peak が大きく増加した。

一方、CPU/GPU 系の条件では、概ね normal_loud として安定した出力が得られた。Float32 × cpuAndGPU では単発初回に clipping が観測されたが、warm-up を入れることで manual baseline と一致した。

各条件の安定性を一覧にすると下図のとおりで、Neural Engine を含むすべての条件が悪いわけではなく、Float16 および Int8 の HiFi-GAN が Neural Engine で実行される条件において、特に破綻が発生することが分かった。

6. ③ 使える音軸：MCD による音質評価

音質評価では、PyTorch 版 PronounSE の出力を baseline とし、各 Core ML 出力との距離を MCD で計測した。MCD は小さいほど baseline に近い音色であることを示す。




Figure 2: キャッシュ後ロード時間（12 セル）

②壊れない軸 —— 安定性マトリクス（HiFi-GAN が ANE 実行の4セルで clipping）

	cpuOnly	cpuAndGPU	cpuAndNE	all
Float32	○ normal	○ normal	○ normal	○ normal
Float16	○ normal	○ normal	✗ clipped	✗ clipped
Int8	○ normal	○ normal	✗ clipped	✗ clipped

Figure 3: 安定性マトリクス（3×4）

結果として、CPU/GPU 系の 8 条件は MCD が 3.9～6.6 dB に収まった。一方、Float16 および Int8 で Neural Engine を含む 4 条件では、MCD が 11.6～12.0 dB まで悪化した。

グループ	MCD	判定
CPU/GPU 系 8 条件	3.9～6.6 dB	使える音の候補
Float16 / Int8 × cpuAndNE / all	11.6～12.0 dB	不成立

特に重要なのは、良い 8 条件と悪い 4 条件の間に約 5 dB のギャップがある点である。このため、MCD の結果からも、Float16 および Int8 の ANE 実行条件は明確に棄却できる。




Figure 4: MCD ランキング（12 セル, 昇順）

ただし、MCD は音色の距離を示す指標であり、人間が聞いたときの自然さや好みを完全に表すものではない。そのため、MCD は足切り指標として用い、最終的には聴感確認も行う必要がある。

7. 破綻箇所の切り分け

ANE 条件で音が壊れる原因を調べるため、実機 snapshot の中間出力を比較した。比較対象は、mel 入力、encoder 出力、postnet 出力、HiFi-GAN 出力波形、最終波形である。

その結果、mel、encoder、postnet までは良い条件と壊れた条件でほぼ一致していた。一方、HiFi-GAN 出力波形の段階で RMS が約 4 倍に増加し、最終波形では clipping が発生していた。

stage	状態
mel_normalized	正常
encoder_output	正常
postnet_output	正常
waveform_predeemph	RMS が約 4 倍に増加
waveform_postdeemph	clipping

この結果から、破綻は encoder や decoder ではなく、主に HiFi-GAN vocoder を Neural Engine で実行した段階で発生していると考えられる。

ただし、本研究の主目的は HiFi-GAN の ANE 内部挙動を低レイヤまで解明することではない。ここでの切り分けは、実用的な実行条件を選定するための補足的な分析である。

8. 成立マップ

3 軸の評価結果をまとめると、次の成立マップのようになる。

インタラクティブ成立マップ —— 3軸すべてで同じ ANE 4セルが不成立

設定グループ	①速い	②壊れない	③使える音	成立
CPU/GPU系 (F32/F16/Int8 × cpuOnly, cpuAndGPU)	○	○	○	候補
F32 × cpuAndNE, all (実態 CPU/GPU フォールバック)	○	○	○	候補
F16/Int8 × cpuAndNE, all (HiFi-GAN が ANE 実行)	×	×	×	不成立

Figure 5: インタラクティブ成立マップ (3 軸 ○× マトリクス)

この結果から、インタラクティブな効果音生成の成立候補は CPU/GPU 系の条件に絞られる。Neural Engine を含む条件は必ずしも有利ではなく、特に Float16 および Int8 の HiFi-GAN を ANE で実行する場合、ロード時間、安定性、音質のすべてで不成立となった。

9. 考察

一般的には、Neural Engine を使うことで高速かつ省電力な推論が期待される。しかし、本研究の結果では、PronounSE の HiFi-GAN においては、ANE 実行が必ずしも適切ではなかった。

特に、Float16 および Int8 の ANE 実行では、HiFi-GAN の初回ロードに数十秒かかり、出力波形の振幅が大きく膨張し、MCD も大きく悪化した。このことから、音声生成モデル、とくに波形を直接生成する vocoder では、計算ユニットの選択が出力品質に大きく影響する可能性がある。

一方で、CPU/GPU 系の条件では、初回ロードが約 1 秒前後に収まり、安定性も高く、MCD も比較的低かった。そのため、PronounSE を iPhone 上でインタラクティブに動かすには、現時点では CPU/GPU 実行を中心に採用する方が現実的である。

10. 結論

本研究では、声真似から効果音を生成する PronounSE を iPhone 単体で実行し、インタラクティブな効果音生成が成立する条件を、速度・安定性・音質の 3 軸から評価した。

実験の結果、CPU/GPU 系の条件では、ロード時間が約 1 秒前後に収まり、出力も安定し、MCD も 3.9～6.6 dB に収まった。一方、Float16 および Int8 で Neural Engine を含む条件では、HiFi-GAN のロードに数十秒かかり、clipping が発生し、MCD も 11.6～12.0 dB まで悪化した。

したがって、PronounSE の iOS 実装において、Neural Engine は必ずしも最適な実行先ではない。特に、Float16 および Int8 の HiFi-GAN を ANE で実行する条件は、速度・安定性・音質の 3 軸すべてを満たさなかった。現時点では、CPU/GPU 系の実行条件が、スマホ単体でのインタラクティブな効果音生成に適した候補である。

11. 今後の課題

今後は、以下の点を確認する必要がある。

- 入力音声を増やし、CPU/GPU 系 8 条件の順位をより信頼できるものにする
- MCD だけでなく、聴感評価や ABX テストを行う
- 実際のアプリ UI 上で、ユーザーが複数候補を試聴・比較できる体験を検証する
- warm-up やキャッシュ戦略により、初回待ち時間をどこまで隠せるか検討する
- 最終的に採用する精度と計算ユニットを決定する